

6章 固有値・固有ベクトル

武蔵野大学 データサイエンス学部データサイエンス学科
中西 崇文

授業評価アンケート

- <WEBアンケートURL>
<https://musashino-u.e-qs.jp/>
<ID/PW>
MUSE/MUSCATのものと同様です。

基底

- ベクトル空間 V の $\mathbf{u}_1, \mathbf{u}_2, \dots, \mathbf{u}_N$ が線形独立であり、 V の任意の要素がこれらのベクトルの線形結合で表現できるとき、集合 $\{\mathbf{u}_1, \mathbf{u}_2, \dots, \mathbf{u}_N\}$ のことを V の基底とよぶ。また N を V の次元と呼ぶ。
 - $\dim V = N$
 - \mathbf{u}_i を基底ベクトルと呼ぶ


線形独立/線形従属

- N個のスカラー a_1, a_2, \dots, a_N 、N個のベクトル $\mathbf{u}_1, \mathbf{u}_2, \dots, \mathbf{u}_N$ に対して $a_1\mathbf{u}_1 + a_2\mathbf{u}_2 + \dots + a_N\mathbf{u}_N$ を線形結合(*Linear combination*)といい
$$a_1\mathbf{u}_1 + a_2\mathbf{u}_2 + \dots + a_N\mathbf{u}_N = \mathbf{0}$$


となる必要十分条件が $a_1 = a_2 = \dots = a_N = 0$ であるとき、 $\mathbf{u}_1, \mathbf{u}_2, \dots, \mathbf{u}_N$ は線形独立(linearly independent)といい、そうでない場合は線形従属(linearly dependent)であるという。

線形独立を一次独立、線形従属を一次従属という場合もある

線形・非線形




線形




非線形

線形独立/線形従属のイメージ



u_3 を $a_1 u_1 + a_2 u_2$ で表すことは **できない**
 u_2 を $a_1 u_1 + a_3 u_3$ で表すことは **できない**
 u_1 を $a_2 u_2 + a_3 u_3$ で表すことは **できない**

線形独立




u_3 を $a_1 u_1 + a_2 u_2$ で表すことは **できる**
 u_2 を $a_1 u_1 + a_3 u_3$ で表すことは **できる**
 u_1 を $a_2 u_2 + a_3 u_3$ で表すことは **できる**

線形従属


ベクトルの分解[1/2]

- $\mathbf{x} = \begin{bmatrix} 2 \\ 3 \end{bmatrix}$ は $\mathbf{e}_1 = \begin{bmatrix} 1 \\ 0 \end{bmatrix}$, $\mathbf{e}_2 = \begin{bmatrix} 0 \\ 1 \end{bmatrix}$ の単位ベクトルを用いて、
$$\mathbf{x} = 2\mathbf{e}_1 + 3\mathbf{e}_2$$
 と表現できる
- これをベクトルの分解と呼ぶ




ベクトルの分解[2/2]


- $x = \begin{bmatrix} 2 \\ 3 \end{bmatrix}$ は他のベクトル u_1, u_2 でも分解可能
 - $x = a_1 u_1 + a_2 u_2$ と表現できる
- これを線形結合と呼ぶ



基底の取り替え [1/3]




基底の取り替え[2/3]



$$x' = Qx = \begin{bmatrix} -3 & 1 \\ -2 & 1 \end{bmatrix} \begin{bmatrix} 3 \\ 5 \end{bmatrix} = \begin{bmatrix} -9 + 5 \\ -6 + 5 \end{bmatrix} = \begin{bmatrix} -4 \\ -1 \end{bmatrix}$$

基底の取り替え[3/3]



$$Q^{-1} = \begin{bmatrix} -1 & 1 \\ -2 & 3 \end{bmatrix}$$


基底の取り替えも線形変換で表現可

$$x' = Q^{-1}x = \begin{bmatrix} -1 & 1 \\ -2 & 3 \end{bmatrix} \begin{bmatrix} -4 \\ -1 \end{bmatrix} = \begin{bmatrix} 3 \\ 5 \end{bmatrix}$$

Pythonで求めてみよう


基底の取り替えをしながら線形写像

表現行列 A



Pythonで計算してみよう

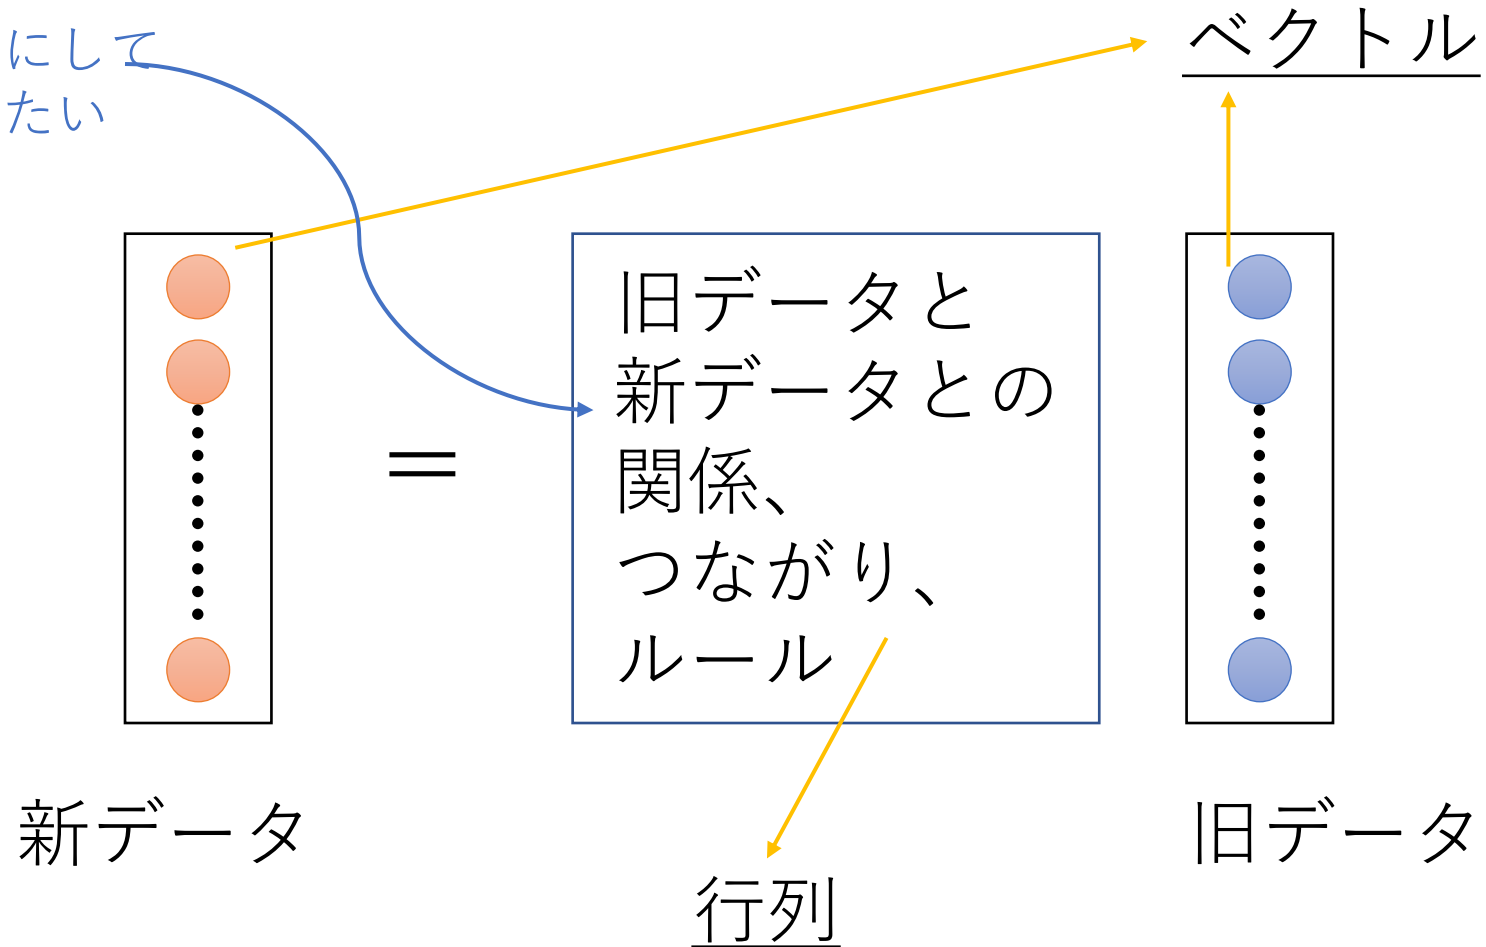
教科書p.163~p.171参照



線形写像/線型変換

旧データから新データへの変換(Transformation)を追求する学問

この行列を簡単にして
計算量を減らしたい



対角行列

- 表現行列 A をうまく P を定めることで、 $P^{-1}AP$ を簡単な行列にできないだろうか？
- -->対角行列

$$\begin{bmatrix} \lambda_1 & 0 & 0 & \cdots & 0 \\ 0 & \lambda_2 & 0 & \cdots & 0 \\ 0 & 0 & \ddots & \ddots & \vdots \\ \vdots & \ddots & \ddots & \ddots & 0 \\ 0 & \cdots & \cdots & 0 & \lambda_n \end{bmatrix}$$

対角行列の性質

- 行列と行列の積が対角要素同士の掛け算で済む

$$\bullet \begin{bmatrix} 2 & 0 & 0 \\ 0 & 3 & 0 \\ 0 & 0 & -4 \end{bmatrix} \begin{bmatrix} -1 & 0 & 0 \\ 0 & -2 & 0 \\ 0 & 0 & 1 \end{bmatrix} = \begin{bmatrix} 2 \times (-1) & 0 & 0 \\ 0 & 3 \times (-2) & 0 \\ 0 & 0 & (-4) \times 1 \end{bmatrix} = \begin{bmatrix} -2 & 0 & 0 \\ 0 & -6 & 0 \\ 0 & 0 & -4 \end{bmatrix}$$

- 行列と行列の積にも関わらず交換法則が成り立つ

$$\bullet \begin{bmatrix} 2 & 0 & 0 \\ 0 & 3 & 0 \\ 0 & 0 & -4 \end{bmatrix} \begin{bmatrix} -1 & 0 & 0 \\ 0 & -2 & 0 \\ 0 & 0 & 1 \end{bmatrix} = \begin{bmatrix} -1 & 0 & 0 \\ 0 & -2 & 0 \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} 2 & 0 & 0 \\ 0 & 3 & 0 \\ 0 & 0 & -4 \end{bmatrix}$$

- 逆行列は対角要素を逆数にしたもの

$$\bullet A = \begin{bmatrix} 2 & 0 & 0 \\ 0 & 3 & 0 \\ 0 & 0 & -4 \end{bmatrix} \rightarrow A^{-1} = \begin{bmatrix} \frac{1}{2} & 0 & 0 \\ 0 & \frac{1}{3} & 0 \\ 0 & 0 & -\frac{1}{4} \end{bmatrix}$$

- 行列のn乗が計算しやすい

$$\bullet A = \begin{bmatrix} 2 & 0 & 0 \\ 0 & 3 & 0 \\ 0 & 0 & -4 \end{bmatrix} \rightarrow A^n = \begin{bmatrix} 2^n & 0 & 0 \\ 0 & 3^n & 0 \\ 0 & 0 & -4^n \end{bmatrix}$$

対角化を考える

- 線形変換 $f: R^n \rightarrow R^n$ の表現行列 A を対角化することを考える

$$\bullet P^{-1}AP = \begin{bmatrix} \lambda_1 & 0 & 0 & \cdots & 0 \\ 0 & \lambda_2 & 0 & \cdots & 0 \\ 0 & 0 & \ddots & \ddots & \vdots \\ \vdots & \ddots & \ddots & \ddots & 0 \\ 0 & \cdots & \cdots & 0 & \lambda_n \end{bmatrix}$$

$$\bullet AP = P \begin{bmatrix} \lambda_1 & 0 & 0 & \cdots & 0 \\ 0 & \lambda_2 & 0 & \cdots & 0 \\ 0 & 0 & \ddots & \ddots & \vdots \\ \vdots & \ddots & \ddots & \ddots & 0 \\ 0 & \cdots & \cdots & 0 & \lambda_n \end{bmatrix}$$

- $P = [\mathbf{x}_1 \quad \mathbf{x}_2 \quad \cdots \quad \mathbf{x}_n]$ とおくと、

$$\bullet A\mathbf{x}_i = \lambda_i \mathbf{x}_i, \\ \mathbf{x}_i \neq 0, \quad i = 1, 2, \dots, n$$

固有値、固有ベクトル

- 与えられた $n \times n$ 行列 A およびスカラー λ に対し、

$$A\mathbf{x} = \lambda\mathbf{x} \quad \text{かつ} \quad \mathbf{x} \neq \mathbf{0}$$

となる \mathbf{x} が存在するとき、 λ を A の固有値(eigenvalue)という。
また、この \mathbf{x} を固有値 λ に属する A の固有ベクトル(eigenvector)という。

固有値、固有ベクトルの求め方[1/2]

$$A\mathbf{x} = \lambda\mathbf{x}$$

$$A\mathbf{x} = \lambda E\mathbf{x}$$

$$A\mathbf{x} - \lambda E\mathbf{x} = \mathbf{0}$$

$$(A - \lambda E)\mathbf{x} = \mathbf{0}$$

$$\begin{aligned}(A - \lambda E)^{-1}(A - \lambda E)\mathbf{x} &= (A - \lambda E)^{-1} \cdot \mathbf{0} \\ E\mathbf{x} &= \mathbf{0} \\ \mathbf{x} &= \mathbf{0}\end{aligned}$$

この逆行列があるとする、 $\mathbf{x} = \mathbf{0}$ になってしまう

$(A - \lambda E)$ は逆行列を持ってはいけない。

逆行列を持たない条件？

行列式 $|A - \lambda E| = 0$ を満たせばよい！

行列式とは

- $A = \begin{bmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{bmatrix}$ の行列式(determinant)は
- $|A| = a_{11}a_{22} - a_{12}a_{21}$ となる
- 行列式が0のときは逆行列が存在しない
- 行列式 $|A| \neq 0$ が行列 A の逆行列 A^{-1} が存在する必要十分条件

固有値、固有ベクトルの求め方[2/2]

- 固有方程式 $|A - \lambda E|=0$ の解 λ が固有値
- λ を代入した $(A - \lambda E)\mathbf{x} = \mathbf{0}$ の非自明解が固有ベクトル

具体的に固有値、固有ベクトルを求める [1/3]

- $A = \begin{bmatrix} 1 & 5 \\ 4 & 2 \end{bmatrix}$ の固有値、固有ベクトルを求める。
- $|A - \lambda E| = \begin{vmatrix} 1 - \lambda & 5 \\ 4 & 2 - \lambda \end{vmatrix} = (1 - \lambda)(2 - \lambda) - 20 = \lambda^2 - 3\lambda - 18 = (\lambda + 3)(\lambda - 6) = 0$
- $(\lambda + 3)(\lambda - 6) = 0$
- $\lambda = -3, 6$
- よって、 A の固有値は $-3, 6$

具体的に固有値、固有ベクトルを求める [2/3]

- 固有値 $\lambda=-3$ のとき

- $(A - \lambda E)\mathbf{x} = \mathbf{0}$ は

$$\begin{bmatrix} 1 - \lambda & 5 \\ 4 & 2 - \lambda \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \mathbf{0}$$

$$\begin{bmatrix} 4 & 5 \\ 4 & 5 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \mathbf{0} \text{ より}$$

$$4x_1 + 5x_2 = 0$$

- $x_1 = 5m, x_2 = -4m$ (m は実数)

- よって、固有値 $\lambda=-3$ に属する A の固有ベクトルは $m \begin{bmatrix} 5 \\ -4 \end{bmatrix}$ (m は実数)

具体的に固有値、固有ベクトルを求める [3/3]

- 固有値 $\lambda=6$ のとき

- $(A - \lambda E)\mathbf{x} = \mathbf{0}$ は

$$\begin{bmatrix} 1 - \lambda & 5 \\ 4 & 2 - \lambda \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \mathbf{0}$$

$$\begin{bmatrix} -5 & 5 \\ 4 & -4 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \mathbf{0}$$
より

$$x_1 - x_2 = 0$$

- $x_1 = m, x_2 = m$ (m は実数)

- よって、固有値 $\lambda=6$ に属する A の固有ベクトルは $m \begin{bmatrix} 1 \\ 1 \end{bmatrix}$ (m は実数)

注意：固有値は大きさは定まっていらないが、方向が定まっている

Pythonで計算してみよう

- $A = \begin{bmatrix} 1 & 5 \\ 4 & 2 \end{bmatrix}$ の固有値、固有ベクトル
 - 固有値 $\lambda=6$ に属する A の固有ベクトルは $m \begin{bmatrix} 1 \\ 1 \end{bmatrix}$ (m は実数)
 - 固有値 $\lambda=-3$ に属する A の固有ベクトルは $m \begin{bmatrix} 5 \\ -4 \end{bmatrix}$ (m は実数)
- 固有値、固有ベクトルを求める関数として、`numpy.linalg.eig(A)` がある

対角化可能

- $n \times n$ 行列(正方行列) A が適当な正則行列 P によって

$$\bullet P^{-1}AP = \begin{bmatrix} \lambda_1 & 0 & 0 & \cdots & 0 \\ 0 & \lambda_2 & 0 & \cdots & 0 \\ 0 & 0 & \ddots & \ddots & \vdots \\ \vdots & \ddots & \ddots & \ddots & 0 \\ 0 & \cdots & \cdots & 0 & \lambda_n \end{bmatrix}$$

- と変形できるとき、 A は対角化可能(diagonalizable)であるという。このとき P を A の対角化行列(matrix for diagonalization)という

対角化可能性

- $n \times n$ 行列(正方行列) A が対角化可能であるための必要十分条件は線形独立な n 個の A の固有ベクトルが存在することである。

- $n \times n$ 行列(正方行列) A が適当な正則行列 $P = [\mathbf{p}_1, \mathbf{p}_2, \dots, \mathbf{p}_n]$ によって、

$$P^{-1}AP = \begin{bmatrix} \lambda_1 & 0 & 0 & \dots & 0 \\ 0 & \lambda_2 & 0 & \dots & 0 \\ 0 & 0 & \ddots & \ddots & \vdots \\ \vdots & \ddots & \ddots & \ddots & 0 \\ 0 & \dots & \dots & 0 & \lambda_n \end{bmatrix}$$

と変形できるとき、 $\lambda_1, \lambda_2 \dots \lambda_n$ はすべて A の固有値であり、 $\mathbf{p}_i (i = 1, 2, \dots, n)$ は固有値 λ_i に属する固有ベクトルである。

固有値とその固有ベクトルの関係

- スカラー $\lambda_1, \lambda_2 \dots \lambda_n$ が $n \times n$ 行列(正方行列) A の相異なる固有値だとすると、それぞれに属する固有ベクトル $\mathbf{p}_1, \mathbf{p}_2 \dots \mathbf{p}_n$ は線形独立である。
- $n \times n$ 行列(正方行列) A が n 個の固有値 $\lambda_1, \lambda_2 \dots \lambda_n$ をもてば A は対角化可能、正則行列 P によって、

$$P^{-1}AP = \begin{bmatrix} \lambda_1 & 0 & 0 & \dots & 0 \\ 0 & \lambda_2 & 0 & \dots & 0 \\ 0 & 0 & \ddots & \ddots & \vdots \\ \vdots & \ddots & \ddots & \ddots & 0 \\ 0 & \dots & \dots & 0 & \lambda_n \end{bmatrix}$$

となる。

Pythonで計算してみよう

$$\bullet A = \begin{bmatrix} 3 & 7 & -1 \\ 4 & 6 & 4 \\ -5 & 5 & -1 \end{bmatrix}$$


を対角化し、そのときの対角化行列を求めてみよう。

対角化とはつまり

- 対角化とは、線形変換 f の表現行列 A について、新しい基底として表現行列 A の固有ベクトルの組を取ることで、線形変換 f の表現行列を固有ベクトルと対となる固有値を対角成分とした対角行列にすること

直交


- ベクトル \mathbf{x}, \mathbf{y} が内積 $\mathbf{x} \cdot \mathbf{y} = 0$ を満たすとき、ベクトル \mathbf{x}, \mathbf{y} は直交する (orthogonal) という



$$\begin{aligned}\mathbf{x} \cdot \mathbf{y} &= \|\mathbf{x}\| \|\mathbf{y}\| \cos \theta \\ \cos 90^\circ &= 0 \text{ だから} \\ \mathbf{x} \cdot \mathbf{y} &= 0\end{aligned}$$

正規直交基底

- ベクトル空間 V の $\mathbf{u}_1, \mathbf{u}_2, \dots, \mathbf{u}_N$ が線形独立であり、 V の任意の要素がこれらのベクトルの線形結合で表現できるとき、集合 $\{\mathbf{u}_1, \mathbf{u}_2, \dots, \mathbf{u}_N\}$ のことを V の基底という。
- 上記の基底となる $\mathbf{u}_1, \mathbf{u}_2, \dots, \mathbf{u}_N$ のどの2つも互いに直交し、かつ $\mathbf{u}_1, \mathbf{u}_2, \dots, \mathbf{u}_N$ それぞれのノルムが1に等しいとき正規直交基底 (orthonormal basis) であるという



正規直交基底だと何がうれしいか？ [1/2]

- 2つのベクトル $\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix}$, $\mathbf{y} = \begin{bmatrix} y_1 \\ y_2 \\ y_3 \end{bmatrix}$ のとき基底が $\mathbf{u}_1, \mathbf{u}_2, \mathbf{u}_3$ であれば、
 $\mathbf{x} = x_1 \mathbf{u}_1 + x_2 \mathbf{u}_2 + x_3 \mathbf{u}_3$,
 $\mathbf{y} = y_1 \mathbf{u}_1 + y_2 \mathbf{u}_2 + y_3 \mathbf{u}_3$ と表せる。

正規直交基底だと何がうれしいか？ [2/2]

- $\mathbf{x} = x_1 \mathbf{u}_1 + x_2 \mathbf{u}_2 + x_3 \mathbf{u}_3$,
 $\mathbf{y} = y_1 \mathbf{u}_1 + y_2 \mathbf{u}_2 + y_3 \mathbf{u}_3$ のとき、

- 内積は

- $$\begin{aligned} \mathbf{x} \cdot \mathbf{y} &= (x_1 \mathbf{u}_1 + x_2 \mathbf{u}_2 + x_3 \mathbf{u}_3) (y_1 \mathbf{u}_1 + y_2 \mathbf{u}_2 + y_3 \mathbf{u}_3) \\ &= x_1 y_1 \mathbf{u}_1 \mathbf{u}_1 + x_2 y_1 \mathbf{u}_2 \mathbf{u}_1 + x_3 y_1 \mathbf{u}_3 \mathbf{u}_1 \\ &\quad + x_1 y_2 \mathbf{u}_1 \mathbf{u}_2 + x_2 y_2 \mathbf{u}_2 \mathbf{u}_2 + x_3 y_2 \mathbf{u}_3 \mathbf{u}_2 \\ &\quad + x_1 y_3 \mathbf{u}_1 \mathbf{u}_3 + x_2 y_3 \mathbf{u}_2 \mathbf{u}_3 + x_3 y_3 \mathbf{u}_3 \mathbf{u}_3 \end{aligned}$$

ごっちゃり

もし、基底 $\mathbf{u}_1, \mathbf{u}_2, \mathbf{u}_3$ が正規直交基底だとしたら、

$$\mathbf{u}_1 \mathbf{u}_1 = \mathbf{u}_2 \mathbf{u}_2 = \mathbf{u}_3 \mathbf{u}_3 = 1$$

$$\mathbf{u}_1 \mathbf{u}_2 = \mathbf{u}_2 \mathbf{u}_3 = \mathbf{u}_1 \mathbf{u}_3 = 0$$

なので

$$\mathbf{x} \cdot \mathbf{y} = x_1 y_1 + x_2 y_2 + x_3 y_3$$

すっきり

正規直交基底では

- 正規直交基底では、内積やベクトルの大きさの計算が標準基底(軸上の単位ベクトルからなる基底)と同じように計算ができる

つまり計算が楽になる！

対称行列

T : 転置

- $A = A^T$ を満たす正方行列を対称行列(*symmetric matrix*)という。

例)

$$\begin{bmatrix} 5 & 3 \\ 3 & 6 \end{bmatrix}$$

$$\begin{bmatrix} 1 & 4 & -5 \\ 4 & 3 & -2 \\ -5 & -2 & 5 \end{bmatrix}$$

結構データをみると対称行列になっていることが多い

対称行列の固有ベクトルの性質

- 対称行列の異なる固有値に属する固有ベクトルは直交する
 - 固有ベクトルの大きさを1にすれば固有ベクトルを正規直交基底にすることができる

Pythonで計算してみよう

- $A = \begin{bmatrix} 3 & 2 & 2 \\ 2 & 3 & -2 \\ 2 & -2 & -1 \end{bmatrix}$

を対角化し、そのときの対角化行列を求めてみよう。

- A の異なる固有値に属する固有ベクトルは直交することを確認してみよう。
- 正規直交基底を並べて作った行列を直交行列(orthogonal matrixと呼ぶ)

対称行列の対角化

- $n \times n$ 対称行列 A が n 個の固有値 $\lambda_1, \lambda_2 \cdots \lambda_n$ をもてば、直交行列 P によって、

$$P^T A P = \begin{bmatrix} \lambda_1 & 0 & 0 & \cdots & 0 \\ 0 & \lambda_2 & 0 & \cdots & 0 \\ 0 & 0 & \ddots & \ddots & \vdots \\ \vdots & \ddots & \ddots & \ddots & 0 \\ 0 & \cdots & \cdots & 0 & \lambda_n \end{bmatrix}$$

が成り立つ。

逆行列ではなく、転置行列であることに注目

固有値分解(スペクトル分解)

- 対称行列 A を

$$A = P \begin{bmatrix} \lambda_1 & 0 & 0 & \cdots & 0 \\ 0 & \lambda_2 & 0 & \cdots & 0 \\ 0 & 0 & \ddots & \ddots & \vdots \\ \vdots & \ddots & \ddots & \ddots & 0 \\ 0 & \cdots & \cdots & 0 & \lambda_n \end{bmatrix} P^T$$

とすることを、対称行列 A の固有値分解(スペクトル分解)
(*spectral decomposition, eigenvalue decomposition*)という。


Pythonで計算してみよう

- $A = \begin{bmatrix} 3 & 2 & 2 \\ 2 & 3 & -2 \\ 2 & -2 & -1 \end{bmatrix}$ について対角化したものが $\begin{bmatrix} -3 & 0 & 0 \\ 0 & 5 & 0 \\ 0 & 0 & 3 \end{bmatrix}$ であるが、 $P^T A P$ が同じ値になることを確かめてみよう。

Webページの重要度をどうきめるのか？ PageRank(Google)

- 検索エンジン
 - 検索された各Webページは単にキーワードがマッチしただけでなく、各ページの重要度を計算し、その重要度が高いほど上位にランキングされるようになっている
 - 重要度→PageRank(Google, Sergey Brin & Larry Page)
- PageRankの考え方
 - 多くの重要度の高いページからリンクされているページは重要度が高いページである
 - どれだけリンクされているか
 - そのリンクされたページのPageRankはどれくらいか

Webページとリンクの関係



$$G = (P, L),$$


$$P = \{1, 2, 3, 4, 5, 6\},$$

$$L = \{(1, 2), (1, 3), (3, 1), (3, 2), (3, 5), (4, 5), (4, 6), (5, 4), (5, 6), (6, 4)\}$$

Webページ i から出るリンク数を o_i として、Webページ j のPageRank r_j は次のように表せる

$$r_j = \sum_{(i,j) \in L} \frac{r_i}{o_i}$$

PageRankの求め方



$$\begin{aligned}
 r_1 &= \frac{r_3}{3} \\
 r_2 &= \frac{r_1}{2} + \frac{r_3}{3} \\
 r_3 &= \frac{r_1}{2} \\
 r_4 &= \frac{r_5}{2} + \frac{r_6}{1} \\
 r_5 &= \frac{r_3}{3} + \frac{r_4}{2} \\
 r_6 &= \frac{r_4}{2} + \frac{r_5}{2}
 \end{aligned}$$

$$\begin{bmatrix} r_1 \\ r_2 \\ r_3 \\ r_4 \\ r_5 \\ r_6 \end{bmatrix} = \begin{bmatrix} 0 & 0 & \frac{1}{3} & 0 & 0 & 0 \\ \frac{1}{2} & 0 & \frac{1}{3} & 0 & 0 & 0 \\ \frac{1}{2} & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & \frac{1}{2} & 1 \\ 0 & 0 & \frac{1}{3} & \frac{1}{2} & 0 & 0 \\ 0 & 0 & 0 & \frac{1}{2} & \frac{1}{2} & 0 \end{bmatrix} \begin{bmatrix} r_1 \\ r_2 \\ r_3 \\ r_4 \\ r_5 \\ r_6 \end{bmatrix}$$

実は固有値1の固有ベクトルがPageRank?

$$\begin{bmatrix} r_1 \\ r_2 \\ r_3 \\ r_4 \\ r_5 \\ r_6 \end{bmatrix} = \begin{bmatrix} 0 & 0 & \frac{1}{3} & 0 & 0 & 0 \\ \frac{1}{2} & 0 & \frac{1}{3} & 0 & 0 & 0 \\ \frac{1}{2} & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & \frac{1}{2} & 1 \\ 0 & 0 & \frac{1}{3} & \frac{1}{2} & 0 & 0 \\ 0 & 0 & 0 & \frac{1}{2} & \frac{1}{2} & 0 \end{bmatrix} \begin{bmatrix} r_1 \\ r_2 \\ r_3 \\ r_4 \\ r_5 \\ r_6 \end{bmatrix}$$

$$\mathbf{r} = A \mathbf{r} \quad \lambda = 1$$

固有値・固有ベクトルの定義


与えられた $n \times n$ 行列 A およびスカラー λ に対し、

$$A\mathbf{x} = \lambda\mathbf{x} \quad \text{かつ} \quad \mathbf{x} \neq \mathbf{0}$$

となる \mathbf{x} が存在するとき、 λ を A の固有値(eigenvalue)という。また、この \mathbf{x} を固有値 λ に属する A の固有ベクトル(eigenvector)という。

固有値1の固有ベクトルを求めればよい

Pythonで計算してみよう



$$\begin{bmatrix} r_1 \\ r_2 \\ r_3 \\ r_4 \\ r_5 \\ r_6 \end{bmatrix} = \begin{bmatrix} 0 & 0 & \frac{1}{3} & 0 & 0 & 0 \\ \frac{1}{2} & 0 & \frac{1}{3} & 0 & 0 & 0 \\ \frac{1}{2} & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & \frac{1}{2} & 1 \\ 0 & 0 & \frac{1}{3} & \frac{1}{2} & 0 & 0 \\ 0 & 0 & 0 & \frac{1}{2} & \frac{1}{2} & 0 \end{bmatrix} \begin{bmatrix} r_1 \\ r_2 \\ r_3 \\ r_4 \\ r_5 \\ r_6 \end{bmatrix}$$

実行結果例)

```
# 固有値1に対応する(lmの2番目(つまりindex=1))固有ベクトル
v[:,1].reshape(-1,1)

array([[ -8.89913143e-16],
       [-4.27609337e-16],
       [-7.27716498e-16],
       [-7.42781353e-01],
       [-3.71390676e-01],
       [-5.57086015e-01]])
```

(注意)

導出した固有ベクトルの成分すべて
マイナスの場合

固有ベクトルは向きだけ決まって、
大きさはきまっていない。


なので、マイナスをかけて全て正に
してもかまわない。

ランダムサーファーマodelによる PageRankの拡張

- 基本のPageRankではユーザはリンクを辿り続ける行動のみを十分な回数を行った後のそのWebページを訪問中である確率とみることが出来る→リンクがなくても他のWebページいくよね？
 - 行動1:
 - 現在、Webページ i を訪問中であり、Webページ i にはリンクがないとする。この場合。リンクを辿る代わりに、次のページ j にそれぞれ $\frac{1}{n}$ (n は全ページ数)で遷移する。
 - これは、Webブラウザのブックマーク、URLの入力等、直接任意のページに行くこと。
 - 行動2:
 - 現在、Webページ i を訪問中であり、Webページ i にはリンクがあるとする。この場合、確率 d でWebページ i からリンクを無作為に1つ選びそのページに遷移するだけでなく、確率 $(1 - d)$ でリンクを辿らず、任意のページに遷移する。
 - 後者はWebブラウザのブックマーク、URLの入力等、直接任意のページに行くこと。
 - PageとBrinは $d = 0.85$ を提案。

個人課題

1. 下記のWebページのリンクの張られ方から、固有値1に属する固有ベクトルを求めることで、各ページのPagerankを求めてみよう。



Austin, David. "How Google finds your needle in the web's haystack." *American Mathematical Society Feature Column* 10.12 (2006).

2. データと数理Iで学修したことで、今後自分の未来創造pjのテーマに役立てられそうなことを具体的な線形代数の用語を使ってA4 1枚でまとめてみよう。
 - 授業の感想、要望等も盛り込んでください。(これについては成績には入りませんので、遠慮なく授業の要望をお知らせください)
 - 1についてはipynbファイルを提出すること、2についてはdocxファイルかpdfファイルを提出すること(つまり、一人2ファイル提出すること。)
 - Google Classroomで提出のこと
(締切はGoogle Classroom参照)